

Práctica 1: Fundamentos de R

Inferencia Estadística 2024-2025

Pablo Fazio Arrabal

Ejecución de un archivo Quarto

1. Compila en tu PC el archivo carga_datos_encuesta.qmd que carga y limpia la base de datos original Datos_Estudiantes.csv.

Carga de datos

1. Utiliza el archivo dataframe_encuesta.RDS, cárgalo bajo el nombre “encuesta”. Copia el código necesario para hacerlo.

```
encuesta <- readRDS("dataframe_encuesta.RDS")
```

2. Comprueba el tipo de objeto que es encuesta. Usa la función class().

```
class(encuesta)
```

```
[1] "data.frame"
```

3. Comprueba los tipos de datos y que sean coherentes con la naturaleza de las variables. Usa la función str() o explora el objeto en el entorno.

```
str(encuesta)
```

```
'data.frame':  62 obs. of  25 variables:
 $ Edad      : int  27 25 24 22 22 22 22 22 22 22 ...
 $ Peso      : num  65 65 49 70 60 70 110 54 74 65 ...
 $ Altura    : num  163 163 157 184 180 172 198 175 186 187 ...
 $ Sexo      : Factor w/ 3 levels "", "1 : Masculino",...: 3 3 3 2 2 2 2 2 2 2 ..
 $ Hermanos  : int   3 1 1 2 4 3 1 1 2 1 ...
```

```

$ Distancia          : num  12 2 5 7 10 20 19 1.5 1.1 1.6 ...
$ NotaMediaGrado     : num  NA 6.5 NA 8.25 6 64 670 6.6 7.65 6.6 ...
$ Probabilidad       : int   1 1 1 1 1 1 NA 1 1 1 ...
$ NotaProbabilidad   : num   6 6 6 8 5 65 NA 76 9 7 ...
$ NotaEsperadaIE     : num   10 5 7 8 6 50 8 10 10 8 ...
$ SatisfaccionGrado  : num   9 6 4 7 7 5 6 7 5 8 ...
$ TiempoMovil        : num   1 130 100 200 235 240 80 200 250 540 ...
$ Instragram         : int   1 0 0 0 0 0 0 1 1 0 ...
$ Tiktok             : int   0 1 1 0 0 0 0 0 0 0 ...
$ Facebook           : int   0 0 0 0 0 0 0 0 0 0 ...
$ BeReal             : int   0 0 0 0 0 0 0 0 0 0 ...
$ X                  : int   0 0 0 1 1 0 1 0 0 0 ...
$ Bluesky            : int   0 0 0 0 0 0 0 0 0 0 ...
$ Threads            : int   0 0 0 0 0 0 0 0 0 0 ...
$ Otra               : int   0 0 0 0 0 0 0 0 0 1 ...
$ Ninguna            : int   0 0 0 0 0 1 0 0 0 1 ...
$ TiempoRedSocialFavorita: num  30 0 45 60 50 0 5 55 30 120 ...
$ FuturoLaboral      : Factor w/ 6 levels "", "1 : Empresa",...: 2 4 4 2 4 1 2 2 2 2 ...
$ InteresInferencia  : Ord.factor w/ 4 levels "Poco"<"Indiferente"<...: 4 2 1 3 3 3 1 3 4 ...
$ RedSocialFavorita   : Factor w/ 5 levels "Instagram","Ninguna",...: 1 4 4 5 5 2 5 1 1 3 ...

```

En su gran mayoría, los datos son variables numéricas salvo en algunos casos que representan clases e incluso estas pueden estar ordenadas.

Limpieza de datos

1. Calcula la media y la mediana de la variable NotaMediaGrado. ¿Qué observas? Escribe una función para la media.

```
mean(encuesta$NotaMediaGrado, na.rm = TRUE)
```

```
[1] 27.80257
```

```
median(encuesta$NotaMediaGrado, na.rm = TRUE)
```

```
[1] 7.19
```

En primer lugar, se observa que usando directamente ‘means(encuesta\$NotaMediaGrado)’ como hay valores desconocidos, el resultado sale NA. Cuando eliminamos estos valores vemos que la media no sale entre 0 y 10 como se presupone, luego habrá valores muy grandes.

```
calculo_media <- function(x){
  x_sin_na <- x[!is.na(x)]
  sum(x_sin_na)/length(x_sin_na)
}
```

```
calculo_media(encuesta$NotaMediaGrado)
```

```
[1] 27.80257
```

2. Calcula la media y la mediana de todas las variables numéricas. Utiliza un bucle for y una condición if y guarda los resultados en un vector. ¿Qué observas?

```
# Construimos un vector con los nombres de las variables numéricas en encuesta
numericas <- c("Edad", "Peso", "Altura", "Hermanos", "Distancia",
               "NotaMediaGrado", "NotaProbabilidad", "NotaEsperadaIE",
               "SatisfaccionGrado", "TiempoMovil", "TiempoRedSocialFavorita")

medias <- numeric(length = length(numericas))
names(medias) <- numericas

for(i in numericas){
  medias[i] <- calculo_media(encuesta[,i])
}

medias
```

Edad	Peso	Altura
21.016129	68.180328	168.026379
Hermanos	Distancia	NotaMediaGrado
1.451613	14.036226	27.802571
NotaProbabilidad	NotaEsperadaIE	SatisfaccionGrado
9.226415	8.475000	6.500000
TiempoMovil	TiempoRedSocialFavorita	
153.532258	58.120968	

```
medianas <- numeric(length = length(numericas))
names(medianas) <- numericas

for(i in numericas){
```

```
medianas[i] <- median(encuesta[,i], na.rm = TRUE)
}

medianas
```

Edad	Peso	Altura
21.00	68.00	173.00
Hermanos	Distancia	NotaMediaGrado
1.00	10.00	7.19
NotaProbabilidad	NotaEsperadaIE	SatisfaccionGrado
7.00	8.00	7.00
TiempoMovil	TiempoRedSocialFavorita	
140.00	47.50	

3. Elimina o modifica manualmente los valores que parezcan erróneos.

Para ello, vamos a eliminar los valores que sean *mayores de 10 en la variable NotaMediaGrado* y los que sean *menores de 100 cm en la variable Altura*.

```
encuesta$NotaMediaGrado[encuesta$NotaMediaGrado > 10] <- NA
encuesta$Altura[encuesta$Altura < 100] <- NA
```

4. Calcula de nuevo la media y la mediana de todas las variables numéricas.

```
for(i in numericas){
  medias[i] <- calculo_media(encuesta[,i])
}

medias
```

Edad	Peso	Altura
21.016129	68.180328	173.964286
Hermanos	Distancia	NotaMediaGrado
1.451613	14.036226	7.245152
NotaProbabilidad	NotaEsperadaIE	SatisfaccionGrado
9.226415	8.475000	6.500000
TiempoMovil	TiempoRedSocialFavorita	
153.532258	58.120968	

```
for(i in numericas){
  medianas[i] <- median(encuesta[,i], na.rm = TRUE)
}

medianas
```

Edad	Peso	Altura
21.0	68.0	173.5
Hermanos	Distancia	NotaMediaGrado
1.0	10.0	7.0
NotaProbabilidad	NotaEsperadaIE	SatisfaccionGrado
7.0	8.0	7.0
TiempoMovil	TiempoRedSocialFavorita	
140.0	47.5	

5. ¿Qué pregunta es la que menos se ha contestado?

```
# Definimos una función que cuente por cada columna el número de valores NA
apply(encuesta, 2, function(x) sum(is.na(x)))
```

Edad	Peso	Altura
0	1	6
Sexo	Hermanos	Distancia
0	0	9
NotaMediaGrado	Probabilidad	NotaProbabilidad
29	1	9
NotaEsperadaIE	SatisfaccionGrado	TiempoMovil
2	0	0
Instragram	Tiktok	Facebook
0	0	0
BeReal	X	Bluesky
0	0	0
Threads	Otra	Ninguna
0	0	0
TiempoRedSocialFavorita	FuturoLaboral	InteresInferencia
0	0	0
RedSocialFavorita		
0		

Hemos creado una función que cuenta el número de valores NA en cada columna y por lo que vemos, la variable **NotaMediaGrado** es la que más se ha dejado en blanco, es decir, la que menos se ha contestado.

6. Crea una matriz (usa la función `matrix`) con nombre `datosnumericos` con las variables que sean numéricas. ¿Qué dimensión tiene? Calcula la media de cada columna usando `colMeans()` y `apply()`.

```
datosnumericos <- as.matrix(encuesta[,numericas])
dim(datosnumericos)
```

```
[1] 62 11
```

La dimensión de la matriz de datos numéricos será de **62 filas** (número de respuestas a la encuesta) **x 11 columnas** (número de variables de tipo numérico).

```
colMeans(datosnumericos, na.rm = TRUE)
```

Edad	Peso	Altura
21.016129	68.180328	173.964286
Hermanos	Distancia	NotaMediaGrado
1.451613	14.036226	7.245152
NotaProbabilidad	NotaEsperadaIE	SatisfaccionGrado
9.226415	8.475000	6.500000
TiempoMovil	TiempoRedSocialFavorita	
153.532258	58.120968	

```
apply(datosnumericos, 2, mean, na.rm = TRUE)
```

Edad	Peso	Altura
21.016129	68.180328	173.964286
Hermanos	Distancia	NotaMediaGrado
1.451613	14.036226	7.245152
NotaProbabilidad	NotaEsperadaIE	SatisfaccionGrado
9.226415	8.475000	6.500000
TiempoMovil	TiempoRedSocialFavorita	
153.532258	58.120968	

7. En general, ¿Se espera subir la nota media con Inferencia Estadística?

```
mean(encuesta$NotaMediaGrado, na.rm = TRUE) < mean(encuesta$NotaEsperadaIE, na.rm = TRUE)
```

```
[1] TRUE
```

Como la media de la variable **NotaMediaGrado** es menor que la media de la variable **NotaEsperadaIE**, se espera que la nota media suba con la calificación de Inferencia Estadística.

Visualización en R base


1. Utiliza la función `table()` para realizar una tabla de frecuencias absolutas de la variable Sexo. Gráficala con la función `barplot()`.

```
tabla_sexo <- table(encuesta$Sexo)
barplot(tabla_sexo)
```




2. Convierte la tabla de frecuencias absolutas en relativas y gráficala.

```
tabla_sexo_rel <- prop.table(tabla_sexo)
barplot(tabla_sexo_rel)
```




3. Utiliza la función `hist()` para hacer un histograma de la variable `NotaMediaGrado`.

```
hist(encuesta$NotaMediaGrado, main = "Histograma de NotaMediaGrado", xlab = "NotaMediaGrado")
```




4. Modifica el parámetro del número de barras y observa valores bajos y altos.

```
hist(encuesta$NotaMediaGrado, main = "Histograma de NotaMediaGrado con 5 barras", xlab = "NotaMediaGrado")
```



```
hist(encuesta$NotaMediaGrado, main = "Histograma de NotaMediaGrado con 20 barras", xlab = "NotaMediaGrado")
```


Histograma de NotaMediaGrado con 20 barras



5. Usa la ayuda de la función `density()` y observa en los ejemplos cómo graficarla con la función `plot()`. Hazlo para la variable `Altura`.


```
plot(density(encuesta$Altura, na.rm = TRUE), main = "Densidad de la variable Altura", xlab =
```

Densidad de la variable Altura




6. Usa la función `boxplot()` para representar la variable Distancia.

```
# Haz el boxplot en horizontal  
boxplot(encuesta$Distancia, horizontal = TRUE, main = "Boxplot de la variable Distancia", xlab = "Distancia")
```



7. Usa la función `plot()` para representar Peso y Altura.

```
plot(encuesta$Peso, encuesta$Altura, main = "Peso vs Altura", xlab = "Peso (kg)", ylab = "Al
```



Visualización en ggplot2


1. Carga la librería.

```
library(ggplot2)
```

Warning: package 'ggplot2' was built under R version 4.4.2

2. Modifica el código siguiente para representar la densidad estimada de la Altura por Sexo.


```
ggplot(encuesta) + geom_density(aes(x = Altura), na.rm = TRUE)
```



En este ejercicio, no tenía claro que se preguntaba. He hecho la función de densidad de la variable Altura, pero independiente del Sexo. Podemos hacer también la densidad de la variable Altura en función de si es masculino o femenino el sexo.

3. Usa el parámetro fill dentro del aes para representar dos densidades, una para masculino y otra para femenino.


```
ggplot(encuesta) + geom_density(aes(x = Altura, fill = Sexo), alpha = 0.5, na.rm = TRUE)
```



4. Modifica el código para hacer un histograma en vez de una densidad con todos los datos y para la variable Distancia.

```
ggplot(encuesta) + geom_histogram(aes(x = Distancia), fill = "lightblue", color = "black", b
```

Histograma de la variable Distancia



5. Modifica el código para hacer un boxplot de la NotaMediaGrado en base al Sexo.

```
ggplot(encuesta) + geom_boxplot(aes(x = NotaMediaGrado, y = Sexo), fill = "lightblue", color
```

