

Práctica 2. Introducción Inferencia Estadística

Inferencia Estadística 2024-2025

Antonio Elías

Sobre distribución en el muestreo

Variable aleatoria Bernoulli

1. De muestre por simulación con muestras de tamaño $n = 3$ que la función de densidad de la muestra $X_1, \dots, X_n$ es igual a

$$f_{\theta}(x_1, \dots, x_n) = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i}.$$

```
theta <- 0.7
n <- 3

num_muestras <- 10000

muestras <- matrix(NA, nrow = num_muestras, ncol = n)

for (i in 1:num_muestras) {
  muestras[i,] <- rbinom(n, size = 1, theta)
}

# Otra forma:t(sapply(1:num_muestras, function(x) rbinom(n, size = 1, theta)))

# Nos da las medias de cada variable que debe corresponder más o menos
#con nuestra theta, colMeans(muestras)

# Vamos a poner nuestra matriz como texto en cada fila "1 1 0"
# las convierto en un character para hacer una tabla y calcular probabilidades empíricas
muestras_character <- apply(muestras, 1, function(x) paste(x, collapse = " "))
```

```
# Vamos a contar cuántas veces aparece cada combinación
probabilidad_empirica <- proportions(table(muestras_caracter))

# Ahora debemos ver que la funcion de densidad coincide con la fórmula del enunciado dado un

probabilidad_teorica_f <- function(x, theta){
  theta^sum(x) * (1 - theta)^(length(x) - sum(x))
}

# Posibles combinaciones de 0 y 1 en 3 variables
posibles_combinaciones <- expand.grid(rep(list(0:1), n))

probabilidad_teorica <- apply(posibles_combinaciones, 1, function(x) probabilidad_teorica_f(x, theta))

# Ponemos los nombres de las combinaciones
names(probabilidad_teorica) <- apply(posibles_combinaciones, 1, function(x) paste(x, collapse=""))

# Comparamos las probabilidades teóricas con las empíricas
cat("Probabilidad teórica: \n")
```

Probabilidad teórica:

```
probabilidad_teorica[names(probabilidad_empirica)]
```

```
0 0 0 0 0 1 0 1 0 0 1 1 1 0 0 1 0 1 1 1 0 1 1 1
0.027 0.063 0.063 0.147 0.063 0.147 0.147 0.343
```

```
cat("\nProbabilidad empírica: \n")
```

Probabilidad empírica:

```
probabilidad_empirica
```


```
muestras_caracter
0 0 0 0 0 1 0 1 0 0 1 1 1 0 0 1 0 1 1 1 0 1 1 1
0.0279 0.0638 0.0624 0.1446 0.0631 0.1530 0.1490 0.3362
```

2. Obtenga por simulación la distribución bajo el muestreo del estadístico definido a continuación y compárelo con el resultado teórico visto en clase.

$$T(X_1, \dots, X_n) = \frac{1}{n} \sum_{i=1}^n X_i.$$

```
# Cálculo del estadístico
media_muestral <- apply(muestras, 1, mean)

# Grafica el diagrama de barras con proporciones
ggplot(data.frame(media_muestral = media_muestral), aes(x = media_muestral)) + geom_bar(aes(
  xlab("Media") + ylab("Distribución Muestral de la Media")
```



3. Repita el ejercicio para un tamaño muestral n grande. ¿Qué ocurre?

Básicamente es que el diagrama de barras cuanto más crece el tamaño muestral, más se parece a una función de distribución normal centrada en 'theta'.

La media muestral de poblaciones exponenciales

Definamos el estadístico media muestral como


$$T(X_1, \dots, X_n) = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

1. Obtenga la distribución bajo el muestreo $\bar{X}$ en una población exponencial con parámetro $\lambda = 2$. Obtenga muestras de tamaño 5. ¿Cómo es la forma de la densidad? ¿Cuánto valen aproximadamente la $E[\bar{X}]$ y la varianza $V[\bar{X}]$?

```
n <- 5
lambda <- 2
num_muestras <- 1000

muestras_exp <- replicate(num_muestras, mean(rexp(n, rate = lambda)))

ggplot(data.frame(muestras_exp), aes(x = muestras_exp)) + geom_histogram(aes(y = after_stat(density)))
```



```
data.frame(muestras_exp) %>% summarise(mean = mean(muestras_exp), variance = var(muestras_exp))
```

```
      mean  variance
1 0.5002625 0.05204079
```

2. Repita el ejercicio anterior para un tamaño muestral grande. ¿Qué ocurre? ¿Cómo es la forma de la densidad? ¿Cuánto valen aproximadamente la $E[\bar{X}]$ y la varianza $V[\bar{X}]$?


```

n <- 1000
lambda <- 2
num_muestras <- 1000

muestras_exp <- replicate(num_muestras, mean(rexp(n, rate = lambda)))

ggplot(data.frame(muestras_exp), aes(x = muestras_exp)) + geom_histogram(aes(y = after_stat(density)))

```



```

data.frame(muestras_exp) %>% summarise(mean = mean(muestras_exp), variance = var(muestras_exp))

```

```

      mean      variance
1 0.5008708 0.0002415133

```

La varianza muestral

Definamos el estadístico varianza muestral como


$$T(X_1, \dots, X_n) = S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

1. Obtenga la distribución bajo el muestreo de la varianza muestral S^2 en una población Normal con parámetros $\mu = 0$ y $\sigma = 1$. Obtenga muestras de tamaño $n = 5$.

```
# varianza de n normales
mu <- 0
sigma <- 1
R <- 1000
n <- 5

varianza <- replicate(R, var(rnorm(n, mean = mu, sd = sigma)))

datos <- data.frame(varianza = varianza)
ggplot(datos) +
  geom_histogram(aes(x = varianza, y = after_stat(density)),
    bins = 10,
    col = 'black',
    fill = 'olivedrab4')
```



```
datos %>% summarise(mean = mean(varianza), variance = var(varianza))
```


```
      mean variance
1 0.9347574 0.4320187
```

2. Repita el ejercicio anterior aumentando el tamaño muestral.

```
mu <- 0
sigma <- 1
R <- 1000
n <- 1000

varianza <- replicate(R, var(rnorm(n, mean = mu, sd = sigma)))

datos <- data.frame(varianza = varianza)
ggplot(datos) +
  geom_histogram(aes(x = varianza, y = after_stat(density)),
    bins = 10,
    col = 'black',
    fill = 'olivedrab4')
```



```
datos %>% summarise(mean = mean(varianza), variance = var(varianza))
```

```
      mean  variance
1 0.9995896 0.00188493
```


Responda a las siguientes preguntas:

- ¿Cuáles parecen ser los valores de $E[S^2]$? ¿Son estos valores aceptables?
 - ¿Coinciden en ambos casos los valores de $V[S^2]$?
 - ¿Qué observas en cuanto a la forma de las distribuciones?
3. Repita el ejercicio de los puntos 1-2 para $\sigma = 2$ y responda a las preguntas anteriores.

```
# varianza de n normales
mu <- 0
sigma <- 2
R <- 1000
n <- 10000

varianza <- replicate(R, var(rnorm(n, mean = mu, sd = sigma)))

datos <- data.frame(varianza = varianza)
ggplot(datos) +
  geom_histogram(aes(x = varianza, y = after_stat(density)),
    bins = 10,
    col = 'black',
    fill = 'olivedrab4')
```





```
datos %>% summarise(mean = mean(varianza), variance = var(varianza))
```

```
      mean    variance  
1 4.000879 0.003045753
```

4. Repita el ejercicio de los puntos 1-2 generando datos de una distribución exponencial con parámetro $\lambda = 1$ y responda a las preguntas anteriores.

```
# varianza de n normales  
lambda <- 1  
R <- 1000  
n <- 10000  
  
varianza <- replicate(R, var(rexp(n, rate = lambda)))  
  
datos <- data.frame(varianza = varianza)  
  
ggplot(datos) +  
  geom_histogram(aes(x = varianza, y = after_stat(density)),  
                 bins = 10,  
                 col = 'black',  
                 fill = 'olivedrab4')
```



```
datos %>% summarise(mean = mean(varianza), variance = var(varianza))
```

	mean	variance
1	1.000281	0.0007693802