

Práctica 3. Muestreo Aleatorio

Inferencia Estadística 2024-2025

Antonio Elías

Ejercicio 1

Sea $X_1, \dots, X_n$ una secuencia de variables aleatorias con distribución exponencial con esperanza 1. ¿Cuál es la probabilidad de que la media muestral diste en más de 0.1 de la poblacional?

1. Dé el valor aproximado por el Teorema Central del Límite.

Se nos pide calcular $P(|\bar{x} - \mu| > 0.1)$. Para ello, podemos usar el **Teorema Central del Límite** ($\frac{\hat{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} N(0,1)$). Luego, $P(\frac{|\hat{x} - \mu|}{\sigma/\sqrt{n}} > 0.1/(\sigma/\sqrt{n})) = P(|Z| > \sqrt{30} * 0.1) = 2 * P(Z \leq -0.5477)$.

```
mu <- 1
n <- 30
epsilon <- 0.1

2*pnorm(-sqrt(n)*epsilon)
```

```
[1] 0.5838824
```

2. Aproxime esta probabilidad por simulación.

```
# Definimos las variables necesarias
n <- 30
lambda <- 1
epsilon <- 0.1
num_muestras <- 1000

# Construimos una matriz con n filas y num_muestras columnas

muestras <- matrix(rexp(num_muestras*n, lambda) , nrow = n, ncol = num_muestras)
```

```
medias <- apply(muestras, 2, mean)

probabilidad_final <- mean(abs(medias - 1/lambda) > epsilon)

probabilidad_final
```

```
[1] 0.611
```

```
# Muestra de tamaño 30 de la distribución exponencial con rate lambda
# rexp(n, rate = lambda)

# Mirar la probabilidad que diste mayor de 0.1
# abs(mean(rexp(n, rate = lambda))- 1/lambda) > epsilon
```

3. Calcule el valor exacto y compare los resultados.

La probabilidad teórica para una $Exp(\lambda)$ vimos en clase que se podía ver como la distribución $Gamma(n, n\lambda)$. Luego, $P(|\bar{x} - \mu| > 0.1) = P(|\bar{x} - (1/\lambda)| > 0.1) = P(-0.1 + (1/\lambda) > \bar{x}) + P(0.1 + (1/\lambda) < \bar{x}) = P(\bar{x} > 1.1) + P(\bar{x} < 0.9)$.

```
(1 - pgamma(1.1,n,n*lambda)) + pgamma(0.9,n,n*lambda)
```

```
[1] 0.5838359
```

Ejercicio 2

Ley de Grandes Números

Sea $\bar{X} = \sum_{i=1}^n X_i$ siendo $X_1, \dots, X_n$ una secuencia de variables aleatorias independiente e idénticamente distribuidos.

1. Enuncie y demuestre la Ley (débil) de Grandes Números.
2. Ilustre por simulación la Ley de Grandes Números. Suponga que $X \sim N(0, 1)$.


```

num_muestras <- 100
epsilon <- 0.01
seq_N <- 2:1000

mean_samples_mean <- sapply(seq_N, function(x) mean(replicate(num_muestras, mean(rnorm(x))))))

ggplot(data = data.frame(x = seq_N, y = mean_samples_mean), aes(x = x, y = y)) + geom_line()

```



Ejercicio 3

Convergencia en probabilidad de la varianza de S^2

Siendo $X_1, \dots, X_n$ una secuencia de variables aleatorias independiente e idénticamente distribuidos con media μ y varianza σ^2 . Definamos la variable aleatoria cuasivarianza muestral como $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$.

1. Ilustre por simulación la convergencia en probabilidad de $E[S^2]$ a σ^2 para $X \sim N(0, 1)$.

Debemos ver que $\lim_{n \rightarrow \infty} P(|S_n^2 - \sigma^2| > \epsilon) = 0$. Es decir, ilustraremos un gráfico en el que, a mayor tamaño de 'n', la diferencia entre la varianza muestral y la varianza poblacional es menor y se establece dentro de un intervalo de confianza $(-\epsilon, \epsilon)$.

```
# Definamos una función que dado un vector de tamaño n
# se calcule su cuasivarianza muestral
```

```
funcion_s2 <- function(vectorN){
  n <- length(vectorN)
  mean_vector <- mean(vectorN)
  return((1/(n-1))*sum((vectorN - mean_vector)^2))
}
```

```
num_muestras <- 100
```

```
epsilon <- 0.01
```

```
seq_N <- 2:1200
```

```
sigma <- 1
```

```
mean_sample_var <- sapply(seq_N, function(x)
```

```
  mean(replicate(num_muestras, funcion_s2(rnorm(x)))) - sigma^2)
```


```
data.frame(DifVariance = mean_sample_var, sample_size = seq_N) %>%
```

```
ggplot() +
```

```
geom_line(aes(x = sample_size, y = DifVariance)) +
```

```
geom_hline(yintercept = c(-epsilon, epsilon), color = "red") +
```


```
theme_minimal()
```



2. Observe el comportamiento de la varianza de la varianza muestral $V[S^2]$ cuando $n \rightarrow \infty$.

```
var_sample_var <- sapply(seq_N, function(x)
  var(replicate(num_muestras, funcion_s2(rnorm(x)))))

data.frame(Variance = var_sample_var, sample_size = seq_N) %>%
  ggplot() +
  geom_line(aes(x = sample_size, y = Variance), color = "blue")
```



Ejercicio 4.

Dependencia/Independencia de la media y la varianza muestral.

Muestre por simulación la relación estadística existente entre la media $\bar{X}$ y la cuasivarianza σ^2 muestral. Use $X \sim N(0, 1)$.


1. Grafique la media contra la varianza muestral en un gráfico de puntos.

```
n <- 30
num_muestras <- 1000

muestras <- matrix(rnorm(n*num_muestras), nrow = n, ncol = num_muestras)
```

```
medias <- apply(muestras, 2, mean)
varianzas <- apply(muestras, 2, funcion_s2)

data.frame(Mean = medias, Variance = varianzas) %>%
  ggplot() +
  geom_point(aes(x = Mean, y = Variance)) +
  theme_minimal()
```



2. Obtenga la distribución muestral de la correlación muestral entre la media y la varianza muestrales. Es decir, defina el estadístico correlación ρ como la variable aleatoria $Y = \rho(\bar{X}, S^2)$ y obtenga su distribución en el muestreo.

```
num_muestras <- 1000
num_simulaciones <- 100
n <- 30

correlacion_muestral <- replicate(num_simulaciones, {
  muestras <- matrix(rnorm(n * num_muestras), nrow = n, ncol = num_muestras)
  cor(apply(muestras, 2, mean), apply(muestras, 2, funcion_s2))
})

data.frame(Correlation = correlacion_muestral) %>%
  ggplot() + geom_histogram(aes(x = Correlation, y = after_stat(density)),
```

```
bins = 10,  
col = 'black',  
fill = 'olivedrab4')
```

