

Práctica 5. Estimación Puntual

Inferencia Estadística 2024-2025

Pablo Fazio Arrabal

Cargue el archivo PRACTICA5.RDS disponible en Campus Virtual usando el siguiente código:

```
library(ggplot2)
datos <- readRDS("PRACTICA5.RDS")
```

Ejercicio 1

Argumente qué distribución o distribuciones de probabilidad podrían haber generado las diez muestras que aparecen como columnas en el `data.frame` nombrado `datos`. (**Ver anexo**).

Ejercicio 2

Sabiendo la familia paramétrica de las distribuciones que generaron los datos, proponga *intuitivamente* algún estimador T (función de la muestra) para aproximar los parámetros de las distribuciones de $X_2, X_3, X_4, X_6, X_8, X_9$ y X_{10} .

Distribución $X_2 \sim \text{Poisson}(\lambda)$

En este primer caso únicamente debemos obtener el parámetro λ de la distribución de Poisson. Para ello, podemos utilizar la **media muestral** como estimador:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i,$$

Esto es debido a que si $X \sim \text{Poisson}(\lambda)$, $E[X] = \lambda$. Luego, usando la muestra `datos` (LGN), podemos estimar el parámetro λ como:


```
lambda_est <- mean(datos$X_2)
lambda_est
```

```
[1] 3.473333
```

Comprobación

```
# Gráfico de barras de X que se distribuye como Poisson(lambda_est)

ggplot(data.frame(x = min(datos$X_2):max(datos$X_2)), aes(x = x)) +
  geom_bar(aes(y = dpois(x, lambda_est)), stat = "identity", fill = "blue", alpha = 0.5) +
  labs(title = "Distribución Poisson con lambda estimado",
       x = "X",
       y = "Frecuencia") +
  theme_minimal()
```



```
# Graficamos la muestra de datos$X_2

ggplot(datos, aes(x = X_2)) + geom_bar(aes(y = ..count.. / sum(..count..)),
                                       fill = "red", alpha = 0.5) +
  labs(title = "Distribución de la muestra X_2",
       x = "X",
       y = "Frecuencia") +
  theme_minimal()
```

Warning: The dot-dot notation (`..count..`) was deprecated in ggplot2 3.4.0.
i Please use `after\_stat(count)` instead.



Distribución $X_3 \sim \text{Binomial}(n, p)$

En este caso, la distribución de X_3 es una Binomial, por lo que debemos estimar los parámetros n y p . Para ello, podemos usar dos estimadores: la **media muestral** y la **cuasivarianza muestral**.

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

Si $X \sim \text{Binomial}(n, p)$, entonces $E[X] = np$ y $\text{Var}(X) = np(1-p)$. Por tanto, podemos despejar los parámetros de la siguiente forma:

$$\bar{X} = np \implies p = \frac{\bar{X}}{n}$$

$$S^2 = np(1-p) \implies n = \frac{S^2}{p(1-p)}$$

Luego, podemos estimar los parámetros n y p como:

$$\hat{p} = 1 - \frac{S^2}{\bar{X}}$$

$$\hat{n} = \frac{\bar{x}}{\hat{p}}$$

Usando ahora la muestra *datos*, hacemos la estimación:

```
media_muestral <- 1/(nrow(datos)) * sum(datos$X_3)
var_muestral <- 1/(nrow(datos) - 1) * sum((datos$X_3 - media_muestral)^2)

p_est <- 1 - (var_muestral / media_muestral)
p_est
```

```
[1] 0.852349
```

```
n_est <- round(media_muestral / p_est)
n_est
```


```
[1] 11
```

Comprobación

```
# Gráfico de barras de X que se distribuye como Binomial(n_est, p_est)


ggplot(data.frame(x = min(datos$X_3):max(datos$X_3)), aes(x = x)) +
  geom_bar(aes(y = dbinom(x, n_est, p_est)), stat = "identity", fill = "blue", alpha = 0.5) +
  labs(title = "Distribución Binomial con n y p estimados",
       x = "X",
       y = "Frecuencia") +
  theme_minimal()
```

Distribución Binomial con n y p estimados



```
# Graficamos la muestra de datos$X_3

ggplot(datos, aes(x = X_3)) + geom_bar(aes(y = ..count.. / sum(..count..)),
                                       fill = "red", alpha = 0.5) +
  labs(title = "Distribución de la muestra X_3",
        x = "X",
        y = "Frecuencia") +
  theme_minimal()
```



Distribución $X_4 \sim Normal(\mu, \sigma)$

En este caso, la distribución de X_4 es una Normal, por lo que debemos estimar los parámetros μ y σ . Para ello, podemos usar dos estimadores: la **media muestral** y la **cuasivarianza muestral**.

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

Si $X \sim Normal(\mu, \sigma)$, entonces $E[X] = \mu$ y $Var(X) = \sigma^2$. Por tanto, podemos estimar los parámetros μ y σ como:

$$\hat{\mu} = \bar{X}$$

$$\hat{\sigma}^2 = S^2$$

Entonces, usando la muestra *datos*, hacemos la estimación:

```
mu_est <- mean(datos$X_4)
sigma_est <- (1/(nrow(datos) - 1)) * sum((datos$X_4 - mu_est)^2)

mu_est
```

```
[1] -0.7569114
```


```
sigma_est
```

```
[1] 8.400277
```

Comprobación


```
# Gráfico de densidad de X que se distribuye como Normal(mu_est, sigma_est)

ggplot(data.frame(x = min(datos$X_4):(max(datos$X_4))), aes(x = x)) +
  geom_line(aes(y = dnorm(x, mu_est, sigma_est)), color = "black") +
  labs(title = "Distribución Normal con mu y sigma estimados",
       x = "X",
       y = "Densidad") +
  theme_minimal()
```



```
# Graficamos la muestra de datos$X_4

ggplot(datos, aes(x = X_4)) + geom_density(aes(y = ..density..),
                                           fill = "red", alpha = 0.5) +
  labs(title = "Distribución de la muestra X_4",
       x = "X",
       y = "Densidad") +
  theme_minimal()
```



Distribución $X_6 \sim \text{Gamma}(\alpha, \lambda)$

En este caso, la distribución de X_6 es una Gamma, por lo que debemos estimar los parámetros α y λ . Para ello, podemos usar dos estimadores: la **media muestral** y la **cuasivarianza muestral**.

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

Si $X \sim \text{Gamma}(\alpha, \lambda)$, entonces $E[X] = \frac{\alpha}{\lambda}$ y $\text{Var}(X) = \frac{\alpha}{\lambda^2}$. Por tanto, podemos estimar los parámetros α y λ como:

$$\hat{\alpha} = \frac{\bar{X}^2}{S^2}$$

$$\hat{\lambda} = \frac{\bar{X}}{S^2}$$

Entonces, usando la muestra *datos*, hacemos la estimación:

```
media_muestral <- mean(datos$X_6)
var_muestral <- (1/(nrow(datos) - 1)) * sum((datos$X_6 - media_muestral)^2)

alpha_est <- (media_muestral^2) / var_muestral
lambda_est <- media_muestral / var_muestral

alpha_est
```

```
[1] 104.0789
```


```
lambda_est
```

```
[1] 4.169221
```

Comprobación


```
# Gráfico de densidad de X que se distribuye como Gamma(alpha_est, lambda_est)

ggplot(data.frame(x = min(datos$X_6):(max(datos$X_6))), aes(x = x)) +
  geom_line(aes(y = dgamma(x, alpha_est, lambda_est)), color = "black") +
  labs(title = "Distribución Gamma con alpha y lambda estimados",
       x = "X",
       y = "Densidad") +
  theme_minimal()
```



```
# Graficamos la muestra de datos$X_6

ggplot(datos, aes(x = X_6)) + geom_density(aes(y = ..density..),
                                           fill = "red", alpha = 0.5) +
  labs(title = "Distribución de la muestra X_6",
       x = "X",
       y = "Densidad") +
  theme_minimal()
```



Distribución $X_8 \sim Uniforme(a, b)$

En este caso, la distribución de X_8 es una Uniforme, por lo que debemos estimar los parámetros a y b . Para ello, podemos usar dos estimadores: el **mínimo** y el **máximo** de la muestra.

Si $X \sim Uniforme(a, b)$, entonces $E[X] = \frac{a+b}{2}$ y $Var(X) = \frac{(b-a)^2}{12}$. Por tanto, podemos estimar los parámetros a y b como:

$$\hat{a} = \min(X)$$

$$\hat{b} = \max(X)$$

Esto es debido a que si $X \sim Uniforme(a, b)$, entonces X toma valores entre a y b . Por tanto, el mínimo de la muestra será a y el máximo será b estimada.

Entonces, usando la muestra *datos*, hacemos la estimación:

```
a_est <- min(datos$X_8)
b_est <- max(datos$X_8)

a_est
```

```
[1] -1.488561
```


```
b_est
```

```
[1] 3.712084
```

Comprobación

```
# Gráfico de densidad de X que se distribuye como Uniforme(a_est, b_est)


ggplot(data.frame(x = min(datos$X_8):(max(datos$X_8))), aes(x = x)) +
  geom_line(aes(y = dunif(x, a_est, b_est)), color = "black") +
  labs(title = "Distribución Uniforme con a y b estimados",
       x = "X",
       y = "Densidad") +
  theme_minimal()
```



```
# Graficamos la muestra de datos$X_8

ggplot(datos, aes(x = X_8)) + geom_density(aes(y = ..density..),
                                           fill = "red", alpha = 0.5) +
  labs(title = "Distribución de la muestra X_8",
```

```
x = "X",
y = "Densidad") +
theme_minimal()
```



Distribución $X_9 \sim Normal(\mu, \sigma)$

En este caso, la distribución de X_9 es una Normal, por lo que debemos estimar los parámetros μ y σ . Para ello, podemos usar dos estimadores: la **media muestral** y la **cuasivarianza muestral**.

Antes de eso, eliminamos algunos valores atípicos de la muestra. Para ello, utilizamos el método `boxplot.stats()` de R, que nos permite obtener los valores atípicos de una muestra.

```
outliers <- boxplot.stats(datos$X_9)$out
datosModificados <- datos[!(datos$X_9 %in% outliers), ]
```

Como en el caso de X_4 , si $X \sim Normal(\mu, \sigma)$, entonces $E[X] = \mu$ y $Var(X) = \sigma^2$. Por tanto, podemos estimar los parámetros μ y σ como:

$$\hat{\mu} = \bar{X}$$

$$\hat{\sigma}^2 = S^2$$

Entonces, usando la muestra *datosModificados*, hacemos la estimación:

```
mu_est_9 <- mean(datosModificados$X_9)
sigma_est_9 <- (1/(nrow(datosModificados) - 1)) * sum((datosModificados$X_9 - mu_est_9)^2)

mu_est_9
```


```
[1] -0.4834509
```

```
sigma_est_9
```


```
[1] 9.519053
```

Comprobación

```
# Gráfico de densidad de X que se distribuye como Normal(mu_est_9, sigma_est_9)
ggplot(data.frame(x = min(datosModificados$X_9):(max(datosModificados$X_9))), aes(x = x)) +
  geom_line(aes(y = dnorm(x, mu_est_9, sigma_est_9)), color = "black") +
  labs(title = "Distribución Normal con mu y sigma estimados",
       x = "X",
       y = "Densidad") +
  theme_minimal()
```



```
# Graficamos la muestra de datos$X_9
ggplot(datosModificados, aes(x = X_9)) + geom_density(aes(y = ..density..),
                                                    fill = "red", alpha = 0.5) +
  labs(title = "Distribución de la muestra X_9",
       x = "X",
       y = "Densidad") +
  theme_minimal()
```



Distribución $X_{10} \sim \text{Binomial}(n, p)$

En este caso, la distribución de X_{10} es una Binomial, por lo que debemos estimar los parámetros n y p . Para ello, podemos usar dos estimadores: la **media muestral** y la **cuasivarianza muestral**.

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

Si $X \sim \text{Binomial}(n, p)$, entonces $E[X] = np$ y $\text{Var}(X) = np(1-p)$. Por tanto, podemos estimar los parámetros n y p como:

$$\hat{p} = 1 - \frac{S^2}{\bar{X}}$$

$$\hat{n} = \frac{\bar{x}}{\hat{p}}$$

Entonces, usando la muestra *datos*, hacemos la estimación:

```
outliers2 <- boxplot.stats(datos$X_10)$out
datosModificados2 <- datos[!(datos$X_10 %in% outliers2), ]

media_muestral_10 <- mean(datosModificados2$X_10)
var_muestral_10 <- (1/(nrow(datosModificados2) - 1)) * sum((datosModificados2$X_10 - media_muestral_10)^2)

p_est_10 <- 1 - (var_muestral_10 / media_muestral_10)
p_est_10
```

```
[1] 0.8600621
```

```
n_est_10 <- round(media_muestral_10 / p_est_10)
n_est_10
```


```
[1] 11
```

Comprobación

```
# Gráfico de barras de X que se distribuye como Binomial(n_est_10, p_est_10)


ggplot(data.frame(x = min(datosModificados2$X_10):max(datosModificados2$X_10)), aes(x = x)) +
  geom_bar(aes(y = dbinom(x, n_est_10, p_est_10)), stat = "identity", fill = "blue", alpha = 0.5) +
  labs(title = "Distribución Binomial con n y p estimados",
       x = "X",
       y = "Frecuencia") +
  theme_minimal()
```


Distribución Binomial con n y p estimados



```
# Graficamos la muestra de datos$X_10

ggplot(datosModificados2, aes(x = X_10)) + geom_bar(aes(y = ..count.. / sum(..count..)),
                                                    fill = "red", alpha = 0.5) +
  labs(title = "Distribución de la muestra X_10",
        x = "X",
        y = "Frecuencia") +
  theme_minimal()
```



Ejercicio 3

Las variables X_7 y X_4 están relacionadas como sigue:


$$X_7 = \beta_0 + \beta_1 X_4 + \epsilon,$$

siendo $\beta_0, \beta_1 \in \mathbb{R}$ parámetros y $\epsilon \sim N(0, \sigma^2)$.

Proponga una estimación para los parámetros.

En primer lugar, dibujemos una nube de puntos con los datos de X_4 y X_7 para ver que efectivamente siguen una relación lineal.

```
datos <- readRDS("PRACTICA5.RDS")
ggplot(datos, aes(x = X_4, y = X_7)) +
  geom_point() +
  labs(title = "Nube de puntos entre X4 y X7",
       x = "X4",
       y = "X7") +
  theme_minimal()
```




Además, podemos tratar de ver su recta de regresión teórica. Para ello, utilizamos el método `lm()` de R, que nos permite ajustar un modelo lineal a los datos.

```
ggplot(datos, aes(x = X_4, y = X_7)) +  
  geom_point() +  
  geom_smooth(method = "lm", color = "red") +  
  labs(title = "Recta de regresión entre X4 y X7",  
        x = "X4",  
        y = "X7") +  
  theme_minimal()
```

``geom_smooth()`` using formula = 'y ~ x'

Recta de regresión entre X4 y X7



Veamos ahora una estimación de los parámetros β_0 y β_1 . Para ello, haremos los siguientes cálculos.

1.) En la igualdad, aplicamos la esperanza a ambos lados:

$$E[X_7] = E[\beta_0 + \beta_1 X_4 + \epsilon] = \beta_0 + \beta_1 E[X_4] + E[\epsilon] = \beta_0 + \beta_1 E[X_4]$$

(ya que $\epsilon \sim N(0, \sigma^2)$ y la esperanza es una función lineal).

De esta forma, despejando β_0 , nos queda que $\beta_0 = E[X_7] - \beta_1 E[X_4]$.

2.) Ahora trataremos de calcular la covarianza entre X_4 y X_7 , esto lo hacemos intuitivamente ya que queremos ver como se relacionan las variables:

$$Cov(X_4, X_7) = Cov(X_4, \beta_0 + \beta_1 X_4 + \epsilon) = \beta_0 Cov(X_4, 1) + \beta_1 Cov(X_4, X_4) + Cov(X_4, \epsilon) = \beta_1 Var(X_4)$$

(ya que $Cov(X_4, 1) = 0$ y $Cov(X_4, \epsilon) = 0$) Y obtenemos que, $\beta_1 = \frac{Cov(X_4, X_7)}{Var(X_4)}$.

Usando ahora la muestra *datos* tratemos de estimar los parámetros β_0 y β_1 de la forma siguiente:

$$\bar{\beta}_1 = \frac{s_{x_4 x_7}}{s_{x_4 x_4}}$$

$$\bar{\beta}_0 = \bar{x}_7 - \bar{\beta}_1 \bar{x}_4$$

donde, $s_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$ y $s_{xx} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$.

```
media_x_4 <- mean(datos$X_4)
media_x_7 <- mean(datos$X_7)

cov_x4_x7 <- (1/(nrow(datos)-1))*sum((datos$X_4 - media_x_4) * (datos$X_7 - media_x_7))
var_x4 <- (1/(nrow(datos)-1))*sum((datos$X_4 - media_x_4)^2)

beta_1 <- cov_x4_x7 / var_x4
beta_0 <- media_x_7 - beta_1 * media_x_4
```

```
beta_1
```

```
[1] 1.492829
```


```
beta_0
```

```
[1] 0.602038
```

Dibujemos ahora la recta de regresión usando los parámetros estimados:

```
ggplot(datos, aes(x = X_4, y = X_7)) +
  geom_point() +
  geom_abline(intercept = beta_0, slope = beta_1, color = "red") +
  labs(title = "Recta estimada de regresión entre X4 y X7",
       x = "X4",
       y = "X7") +
  theme_minimal()
```

Recta estimada de regresión entre X4 y X7



Por último, calculemos el parámetro σ^2 de la distribución normal de ϵ . Para ello, calculamos los residuos de la regresión como:

$$\hat{\epsilon} = X_7 - \hat{\beta}_0 - \hat{\beta}_1 X_4$$

y la cuasivarianza de los residuos como:

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n \hat{\epsilon}^2$$

Luego,

```
residuos <- datos$X_7 - (beta_0 + beta_1 * datos$X_4)
var_residuos <- sum(residuos^2) / (nrow(datos) - 2)
var_residuos
```

```
[1] 5.107688
```

Ejercicio 4

Sabiendo la familia paramétrica de las distribuciones y sus parámetros, argumenta cómo podría evaluar la calidad de los estimadores.

Anexo

Los datos han sido generados con distribución base:

- $X_1 \sim \text{Binomial}(n, p)$
- $X_2 \sim \text{Poisson}(\lambda)$
- $X_3 \sim \text{Binomial}(n, p)$
- $X_4 \sim \text{Normal}(\mu, \sigma)$
- $X_5 \sim \text{Exponencial}(\lambda)$
- $X_6 \sim \text{Gamma}(\alpha, \lambda)$
- $X_8 \sim \text{Uniforme}(a, b)$
- $X_9 \sim \text{Normal}(\mu, \sigma)$
- $X_{10} \sim \text{Binomial}(n, p).$

Algunas muestras están contaminadas con datos generados fuera de su distribución base.